

BASIC MATH & STATISTICS (PART III)

พัฒนธัญญ์ วิจิตรวงศ์เจริญ

สารบัญ

- การทดสอบสมมติฐาน
- การวิเคราะห์ความสัมพันธ์
- Scatter plot
- Correlation
- Regression
- Optimization Linear Programming

HYPOTHESIS TESTING (การทดสอบสมมติฐาน)

เมื่อต้องการศึกษาค่าพารามิเตอร์ของประชากร โดยการสุ่มตัวอย่างเพื่อตรวจสอบว่าเป็นไปตามที่กำหนดไว้เดิมหรือไม่

สถิติอย่างเดียว ไม่สามารถใช้ พิสูจน์สิ่งใดๆ ได้

เราใช้อนุมานทางสถิติเพื่อยอมรับ หรือ ปฏิเสธ คำอธิบายต่างๆ โดยอิงกับความเป็นไปได้

การอนุมาน

วัคซีนโควิด
ใช้ได้ดีหรือไม่

ลูกค้าสองกลุ่ม
มีพฤติกรรมเหมือนกันหรือไม่

แคมเปญโฆษณา
เพิ่มยอดขายได้จริงหรือไม่

HYPOTHESIS TESTING (การทดสอบสมมติฐาน)

1. แคมเปญโฆษณา **A** สามารถทำให้ลูกค้าซื้อมากกว่า **3** ชิ้น/เดือน

=> สมมติฐานเกี่ยวกับประชากร **1** กลุ่ม

2. ลูกค้าวัยรุ่นตอนต้น (13-18 ปี) มียอดขายในการซื้อบัตรคอนเสิร์ตมากกว่า วัยรุ่นตอนปลาย (19-25 ปี)

=> สมมติฐานเกี่ยวกับประชากร **2** กลุ่ม

3. เมื่อใช้วัคซีนโควิดชนิด **A** สามารถป้องกันโควิดได้ **80%**

=> สมมติฐานเกี่ยวกับสัดส่วนประชากร **1** กลุ่ม

HYPOTHESIS TESTING (การทดสอบสมมติฐาน)

แคมเปญโฆษณา **A** สามารถทำให้ลูกค้าซื้อมากกว่า 3 ชิ้น/เดือน

$$\mu \geq 3$$

ครั้งที่ 1 สุ่มตัวอย่าง $n = 40$ คน , $\bar{X} = 5.5$

ครั้งที่ 2 สุ่มตัวอย่าง $n = 40$ คน , $\bar{X} = 2.2$

ครั้งที่ 3 สุ่มตัวอย่าง $n = 40$ คน , $\bar{X} = 3.1$

ครั้งที่ 4 สุ่มตัวอย่าง $n = 40$ คน , $\bar{X} = 2.98$

HYPOTHESIS TESTING (การทดสอบสมมติฐาน)

ตั้งข้อสมมติฐานไว้ 2 ข้อสมมติฐานคือ

- H_0 หรือข้อสมมติฐานหลัก (Null Hypothesis)
 - สิ่งที่เราคาดไว้ มีเครื่องหมาย $=, \geq, \leq$
- H_1 หรือ H_a หรือข้อสมมติฐานรอง หรือ ข้อสมมติฐานทางเลือก (Alternative Hypothesis)
 - มีเครื่องหมายตรงข้ามกับสมมติฐานหลัก $\neq, <, >$

ประเภทของการทดสอบสมมติฐาน

1. การทดสอบสองทาง (Two-sided test)

- สมมติฐาน H_1 มีเครื่องหมาย \neq
- เขตปฏิเสธการทดสอบจะมีสองด้าน

$$H_0 : \dots = \dots$$

$$H_1 : \dots \neq \dots$$

2. การทดสอบทางเดียว (One-sided test)

การทดสอบทางขวา (Right-tailed test)

- สมมติฐาน H_1 มีเครื่องหมาย $>$
- เขตปฏิเสธการทดสอบจะอยู่ทางด้านขวา

$$H_0 : \dots \leq \dots$$

$$H_1 : \dots > \dots$$

การทดสอบทางซ้าย (Left-tailed test)

- สมมติฐาน H_1 มีเครื่องหมาย $<$
- เขตปฏิเสธการทดสอบจะอยู่ทางด้านซ้าย

$$H_0 : \dots \geq \dots$$

$$H_1 : \dots < \dots$$

การตั้งสมมติฐาน

1. นักวิชาการเชื่อว่าเด็กไทยเฉลี่ยเล่นอินเทอร์เน็ต **4.5** ชั่วโมงต่อวัน

$$H_0 : \mu = 4.5$$

$$H_1 : \mu \neq 4.5$$

2. สัตวแพทย์คาดว่าสุนัขจะใช้เวลาพักผ่อนหลังผ่าตัดเฉลี่ยอย่างน้อย **5** ชั่วโมง

$$H_0 : \mu \geq 5$$

$$H_1 : \mu < 5$$

การตั้งสมมติฐาน

3. โดยปกติ ยาแก้ปวดจะมีฤทธิ์เฉลี่ยน้อยกว่า 4 ชั่วโมง

$$H_0 : \mu \leq 4$$

$$H_1 : \mu > 4$$

4. นักเรียนชายและนักเรียนหญิงใช้เวลาทบทวนหนังสือก่อนสอบต่างกัน 50 นาที

$$H_0 : \mu_1 - \mu_2 = 50$$

$$H_1 : \mu_1 - \mu_2 \neq 50$$

การตั้งสมมติฐาน

5. ผู้จบปริญญาโทมีเงินเดือนสูงกว่าผู้จบปริญญาตรีในสาขาเดียวกันไม่น้อยกว่า 4,000 บาท

$$H_0 : \mu_1 - \mu_2 \geq 4,000$$

$$H_1 : \mu_1 - \mu_2 < 4,000$$

6. ชาวสวนทุเรียนในจังหวัดระยองมีรายได้เฉลี่ยแตกต่างจากชาวสวนในจังหวัดจันทบุรี

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

การตั้งสมมติฐาน

7.ประชาชนในเขตลาดกระบัง 45% เป็นคนกรุงเทพโดยกำเนิด

$$H_0 : p = 0.45$$

$$H_1 : p \neq 0.45$$

8.เด็กไทยมากกว่า 72% มีผลการทดสอบ IQ ต่ำกว่า 115

$$H_0 : p \leq 0.72$$

$$H_1 : p > 0.72$$

ความน่าจะเป็นของการเกิดข้อผิดพลาดจากการสรุปผล (TYPES OF ERROR)

Type I and Type II Errors

Accept null	Reject null
Null is true	Type I error
Null is false	Type II error
Correct-no error	Correct-no error

22


Type I : ผลบวกว่าง
(Positive False)
Type II : ผลลบว่าง
(Negative false)

ความน่าจะเป็นของการเกิดข้อผิดพลาดจากการ สรุปผล (TYPES OF ERROR)

สถานการณ์	Type I error ผลบวกหลง	Type II error ผลลบหลง
ตัวกรองสแปมอีเมลล์	กรองอีเมลล์ที่ไม่ใช่สแปมทิ้งไปด้วย	ปล่อยอีเมลล์สแปมเข้ามาในกล่องข้อความ
การตรวจคัดกรองโควิด	ผลเป็นบวก ทั้ง ๆที่ไม่ได้เป็น	ผลเป็นลบ ทั้ง ๆที่เป็น
การจับกุมผู้ต้องหา	ผู้บริสุทธิ์ติดคุก	ผู้ต้องหาหลอยนวน

ความน่าจะเป็นของการเกิดข้อผิดพลาดจากการ สรุปผล (TYPES OF ERROR)


Type I Error



Type II Error



ความน่าจะเป็นของการเกิดข้อผิดพลาดจากการสรุปผล (TYPES OF ERROR)



ความน่าจะเป็นของการเกิดข้อผิดพลาดจากการ สุ่มผล (TYPES OF ERROR)


วิธีการลดค่าความผิดพลาด

- เพิ่มช่วงการยอมรับ
- เพิ่มขนาดของตัวอย่าง n

ขั้นตอนการทดสอบสมมติฐาน


- 1) ตั้งสมมติฐานหลักและสมมติฐานรอง
- 2) กำหนดตัวสถิติทดสอบเป็น Z หรือ t
- 3) หาค่าวิกฤต Z_α , $Z_{\alpha/2}$, t_α , $t_{\alpha/2}$
- 4) กำหนดกฎของการตัดสินใจ
- 5) คำนวณค่าสถิติ
- 6) สรุปผล

กฎการตัดสินใจ



This Photo by Unknown Author is licensed under [CC BY-SA-NC](#)

ปฏิเสธ H_0 เมื่อ $z < -Z_{\alpha/2}$ หรือ $z > Z_{\alpha/2}$



This Photo by Unknown Author is licensed under [CC BY-SA](#)

ปฏิเสธ H_0 เมื่อ $z < -Z_{\alpha}$

การทดสอบค่าพารามิเตอร์

การทดสอบค่าเฉลี่ย

การทดสอบผลต่างของค่าเฉลี่ย

การทดสอบความเท่ากันของค่าเฉลี่ยเมื่อค่าสังเกตเป็นคู่

การทดสอบสัดส่วน

การทดสอบค่าความแปรปรวน

การทดสอบอัตราส่วนของค่าความแปรปรวน

I. การทดสอบสมมติฐานค่าเฉลี่ยประชากรหนึ่งกลุ่ม

สมมติฐานหลักและสมมติฐานรอง

$$H_0 : \mu = \mu_0$$
$$H_1 : \mu \neq \mu_0$$

$$H_0 : \mu \geq \mu_0$$
$$H_1 : \mu < \mu_0$$

$$H_0 : \mu \leq \mu_0$$
$$H_1 : \mu > \mu_0$$

สถิติทดสอบ

กรณีทราบความแปรปรวนประชากร (σ^2)

$$Z = \frac{\bar{x} - \mu}{\sigma / \sqrt{n}}$$

กรณีไม่ทราบความแปรปรวนประชากร (σ^2)

$n > 30$

$$Z = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

$n < 30$

$$t = \frac{\bar{x} - \mu}{s / \sqrt{n}},$$
$$d.f. = n - 1$$

ตัวอย่าง

ผู้จัดการรีสอร์ทกำหนดระดับความพึงพอใจของผู้ใช้บริการไว้ว่าจะต้องไม่ต่ำกว่า **4.2** คะแนน จึงต้องสำรวจความพึงพอใจอย่างสม่ำเสมอ เมื่อสำรวจผู้ให้บริการจำนวน **49** คนพบว่ากลุ่มตัวอย่างมีความพึงพอใจ **4.02** คะแนน ค่าเบี่ยงเบนมาตรฐาน **1.24** จงทดสอบว่าเป็นไปอย่างที่กำหนดหรือไม่ ที่ระดับนัยสำคัญทางสถิติ **0.1**

ตัวอย่าง

1) ตั้งสมมติฐานหลักและสมมติฐานรอง

$$H_0 : \mu \geq 4.2$$


$$H_1 : \mu < 4.2$$

2) กำหนดสถิติทดสอบเป็น z

$$z = \frac{\bar{x} - \mu}{s / \sqrt{n}}$$

3) หาค่าวิกฤต

- เป็นการทดสอบทางเดียวแบบทางซ้าย ใช้ค่า z_α
- ที่ $\alpha = 0.1$ เปิดตาราง ค่า $z_\alpha = 1.28$



$$-z_\alpha = -1.28$$

ตัวอย่าง

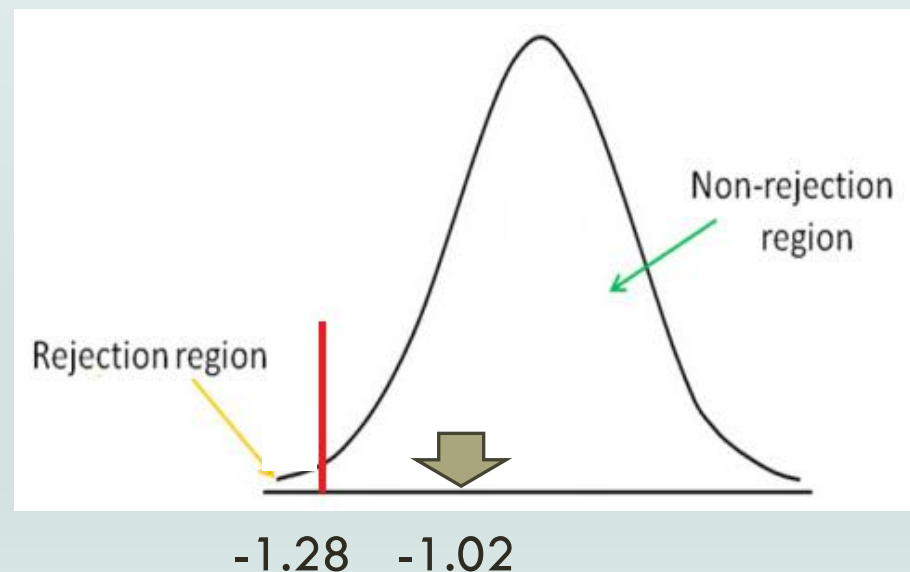
4) กำหนดกฎของการตัดสินใจ
จะปฏิเสธ H_0 เมื่อ $z < -1.28$

5) คำนวณค่าสถิติทดสอบ

$$z = \frac{4.02 - 4.2}{1.24 / \sqrt{49}} = -1.02$$

6) สรุปผล

ยอมรับ H_0 ความพึงพอใจของผู้ใช้บริการไม่ต่ำกว่า 4.2
ที่ระดับนัยสำคัญ 0.1



II. การทดสอบสมมติฐานของผลต่างค่าเฉลี่ย ประชากรสองกลุ่ม

สมมติฐานหลักและสมมติฐานรอง

$$H_0 : \mu_1 - \mu_2 = \mu_0$$

$$H_1 : \mu_1 - \mu_2 \neq \mu_0$$

$$H_0 : \mu_1 - \mu_2 \geq \mu_0$$

$$H_1 : \mu_1 - \mu_2 < \mu_0$$

$$H_0 : \mu_1 - \mu_2 \leq \mu_0$$

$$H_1 : \mu_1 - \mu_2 > \mu_0$$

สถิติทดสอบ

กรณีทราบความแปรปรวนประชากร (σ_1^2, σ_2^2)

$$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n} + \frac{\sigma_2^2}{n}}}$$

กรณีไม่ทราบความแปรปรวนประชากร (σ_1^2, σ_2^2)

$$n > 30$$

$$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{n}}}$$

ตัวอย่าง

สุ่มตัวอย่างหลอดไฟจากบริษัท **A** **60** หลอด ปรากฏว่ามีอายุการใช้งานเฉลี่ย **1,300** ชั่วโมง ส่วนเบี่ยงเบนมาตรฐาน **90** ชั่วโมง และสุ่มตัวอย่างบริษัท **B** มา **50** หลอด ปรากฏว่ามีอายุการใช้งานเฉลี่ย **1,060** ชั่วโมง ส่วนเบี่ยงเบนมาตรฐาน **70** ชั่วโมง จงทดสอบสมมติฐานว่า หลอดไฟจากบริษัท **A** มีอายุการใช้งานนานกว่าหลอดไฟจากบริษัท **B** มากกว่า **200** ชั่วโมง ที่ระดับนัยสำคัญทางสถิติ **0.01** หรือไม่

ตัวอย่าง

1) ตั้งสมมติฐานหลักและสมมติฐานรอง


$$H_0 : \mu_1 - \mu_2 \geq \mu_0$$
$$H_1 : \mu_1 - \mu_2 < \mu_0$$

2) กำหนดสถิติทดสอบเป็น z

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n} + \frac{s_2^2}{n}}}$$

3) หาค่าวิกฤต

- เป็นการทดสอบทางเดียวแบบทางขวา ใช้ค่า z_α
- ที่ $\alpha = 0.01$ เปิดตาราง ค่า $z_\alpha = 2.33$



$$z_\alpha = 2.33$$

ตัวอย่าง


4) กำหนดกฎของการตัดสินใจ
จะปฏิเสธ H_0 เมื่อ $z > 2.33$

5) คำนวณค่าสถิติทดสอบ

$$z = \frac{(1300 - 1060) - (200)}{\sqrt{\frac{90^2}{60} + \frac{70^2}{50}}} = 2.62$$

6) สรุปผล

ปฏิเสธ H_0 หลอดไฟจากบริษัท A มีอายุการใช้งานนานกว่าหลอดไฟจากบริษัท B มากกว่า 200 ชม. ที่นัยสำคัญ 0.01



III. การทดสอบสมมติฐานของค่าสัดส่วนประชากร

สมมติฐานหลักและสมมติฐานรอง

$$H_0 : p = p_0$$

$$H_1 : p \neq p_0$$

$$H_0 : p \geq p_0$$

$$H_1 : p < p$$

$$H_0 : p \geq p_0$$

$$H_1 : p < p_0$$

สถิติทดสอบ

$$z = \frac{\hat{p} - p}{\sqrt{\frac{pq}{n}}}$$

เมื่อ $q = 1 - p$

ตัวอย่าง

จากการสำรวจโพลของ **ABC** เชื่อว่า **72%** ของคนที่เล่นอินเทอร์เน็ต จะถูกขโมยข้อมูลทางอินเทอร์เน็ต จึงทำการสุ่มตัวอย่างนักศึกษาที่เล่นอินเทอร์เน็ตจำนวน **300** คน จากมหาวิทยาลัยแห่งหนึ่ง พบว่า **228** คนถูกขโมยข้อมูล จึงทดสอบความเชื่อนี้ที่ระดับนัยสำคัญ **0.10**

ตัวอย่าง

1) ตั้งสมมติฐานหลักและสมมติฐานรอง

$$H_0 : p = 0.72$$


$$H_1 : p \neq 0.72$$

2) กำหนดสถิติทดสอบเป็น z

$$z = \frac{\hat{p} - p}{\sqrt{\frac{pq}{n}}}$$

3) หาค่าวิกฤต

- เป็นการทดสอบสองทางใช้ค่า $z_{\alpha/2}$
- ที่ $\alpha = 0.1$, $\frac{\alpha}{2} = 0.05$ เปิดตาราง
ค่า $z_{\alpha/2} = 1.645$



ตัวอย่าง

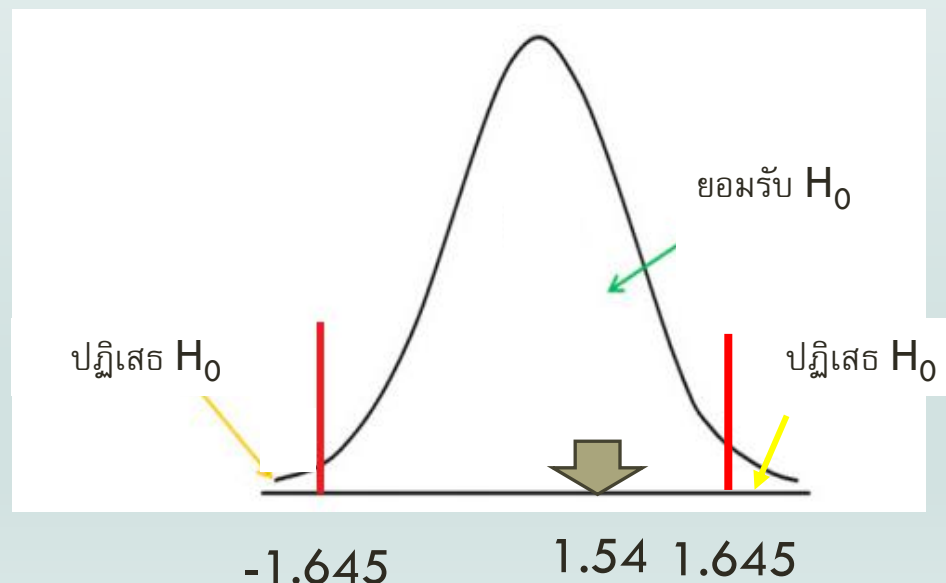
4) กำหนดกฎของการตัดสินใจ
จะปฏิเสธ H_0 เมื่อ $z < -1.645$ หรือ
 $z > 1.645$

5) คำนวณค่าสถิติทดสอบ

$$z = \frac{0.76 - 0.72}{\sqrt{\frac{0.72(1-0.72)}{300}}} = 1.54$$

6) สรุปผล

ยอมรับ H_0 มีคนที่เล่นอินเทอร์เน็ตและถูกขโมยข้อมูล
ทางอินเทอร์เน็ต 72% จริงที่ระดับนัยสำคัญ 0.10



P-VALUE

ความน่าจะเป็นที่น้อยที่สุด ที่สามารถจะปฏิเสธสมมติฐานหลักได้



ระดับความเชื่อมั่นสูงสุดที่สามารถปฏิเสธ
สมมติฐานหลักได้ (**1-P-value**)


$$P - Value = \Pr(Z > |z_c|)$$

ค่าความน่าจะเป็นที่ค่าสถิติที่เหมาะสมนั้นมีค่ามากกว่าค่าสัมบูรณ์ของค่าสถิติที่คำนวณได้

P-VALUE

Standard Normal Model


P-value



$$H_a : p_1 - p_2 < 0$$

Left-tailed P-value


P-value



$$H_a : p_1 - p_2 > 0$$

Right-tailed P-value

P-value is
double this area



$$H_a : p_1 - p_2 \neq 0$$

Two-tailed P-value

P-VALUE

กรณีที	สรุปผล
$P\text{-Value} < \alpha$	Reject H_0 (ปฏิเสธสมมติฐานหลัก)
$P\text{-Value} > \alpha$	Accept H_0 (ยอมรับสมมติฐานหลัก)


การวิเคราะห์ความสัมพันธ์

การวิเคราะห์ความสัมพันธ์


ตัวแปร X กับ Y มีความสัมพันธ์กันอย่างไร

- Netflix
- อุณหภูมิ กับ ผลผลิต
- ฤดูกาล กับ ยอดขาย

SCATTER PLOT (การกระจาย)



[This Photo](#) by Unknown Author is licensed under [CC BY-SA](#)



[This Photo](#) by Unknown Author is licensed under [CC BY-SA](#)

CORRELATION สหสัมพันธ์

ทำหน้าที่ยืนยันว่า ปรากฏการณ์สองอย่างสัมพันธ์กันเพียงใด

อุณหภูมิในฤดูร้อน

ยอดขายไอศกรีม

+

ส่วนสูง

น้ำหนัก

-

การออกกำลังกาย

น้ำหนัก

-

CORRELATION สหสัมพันธ์

Correlation VS Causation



ยอดขายชุดว่ายน้ำ

VS



ยอดขายไอศกรีม

CORRELATION สหสัมพันธ์

- **Linear Correlation** สหสัมพันธ์เชิงเส้น เป็นการศึกษาว่ามีความสัมพันธ์เป็นเส้นตรงมากน้อยเพียงใด
- สัมประสิทธิ์สหสัมพันธ์ **Coefficient of Correlation**

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Where,

r = Pearson Correlation Coefficient

x_i = x variable samples

y_i = y variable sample

\bar{x} = mean of values in x variable

\bar{y} = mean of values in y variable


CORRELATION สหสัมพันธ์

◆ มีค่าระหว่าง -1 กับ 1


ค่าเข้าใกล้ $1 \Rightarrow$ สัมพันธ์เชิงบวกอย่างสมบูรณ์

ค่าเข้าใกล้ $-1 \Rightarrow$ สัมพันธ์เชิงลบอย่างสมบูรณ์


◆ ไม่ยึดติดกับหน่วยวัดใดๆ



(a) Positive correlation

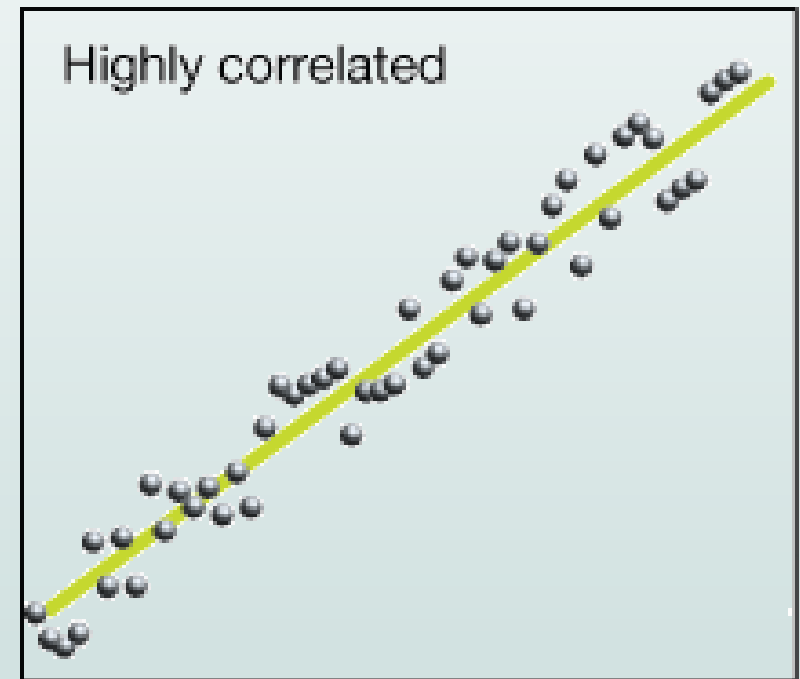


(b) Negative correlation



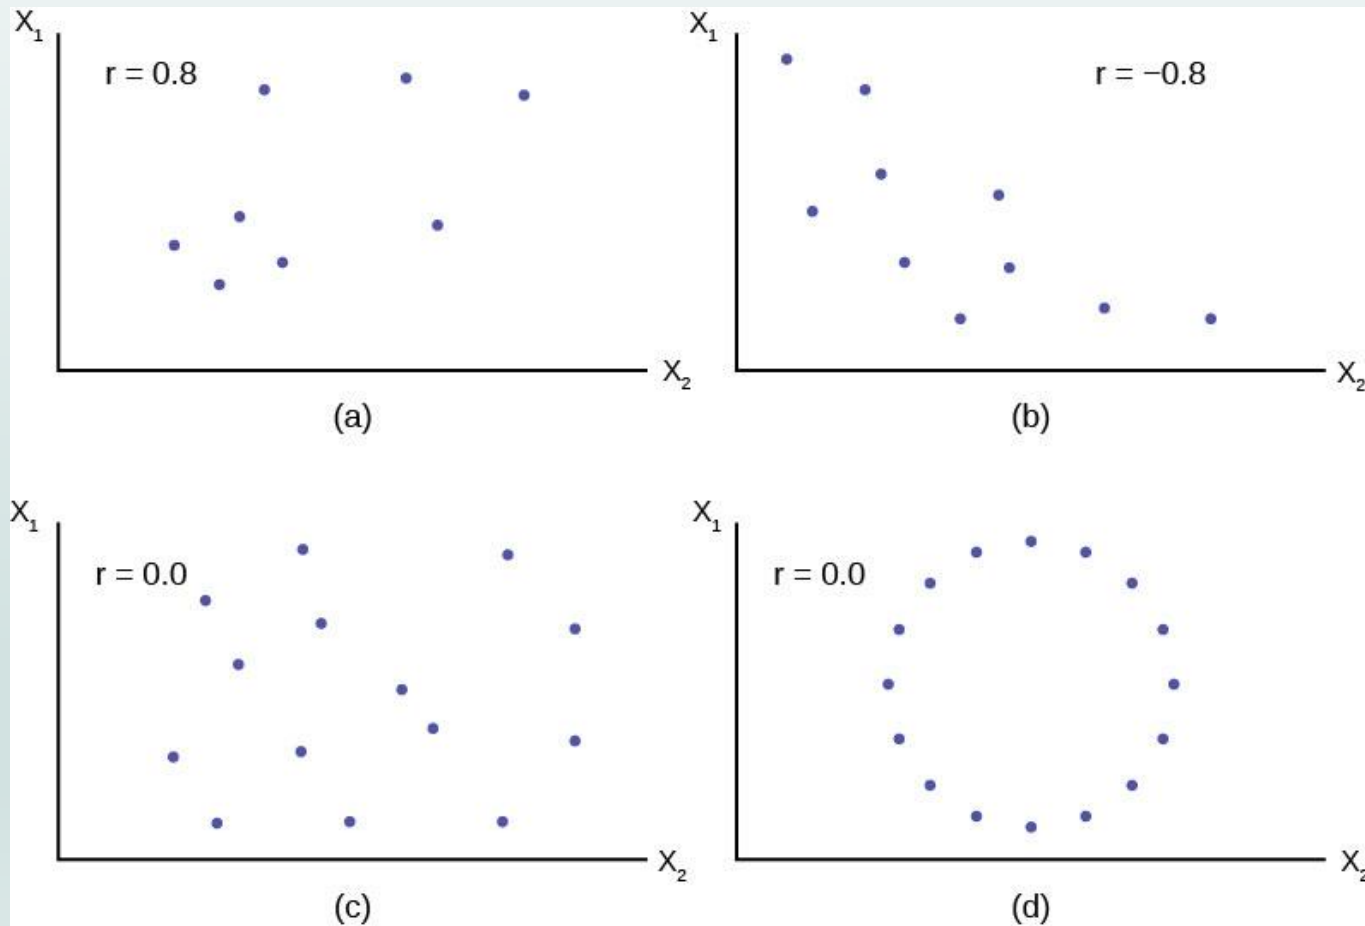
(c) Zero correlation

[This Photo](#) by Unknown Author is licensed under [CC BY](#)

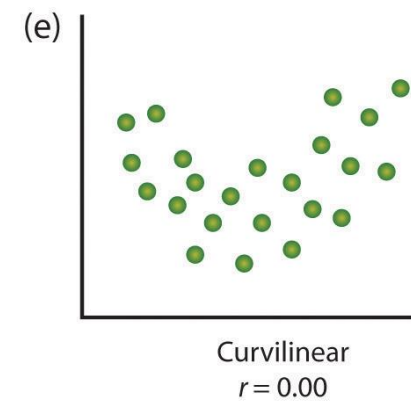



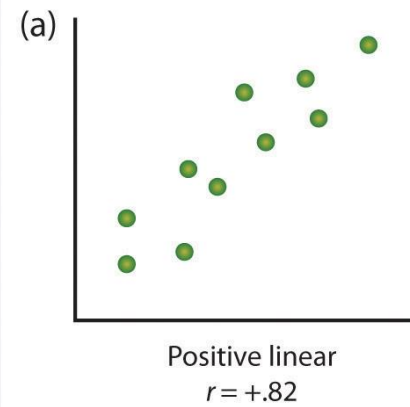


[This Photo](#) by Unknown Author is licensed under [CC BY-SA-NC](#)


CORRELATION สหสัมพันธ์



CORRELATION สหสัมพันธ์



CORRELATION สหสัมพันธ์



ตัวอย่าง

เจ้าของร้านน้ำแข็งใส อยากรู้ว่า
อุณหภูมิมีความสัมพันธ์กับปริมาณ
น้ำแข็งใสที่ถูกซื้อไปหรือไม่

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Where,

r = Pearson Correlation Coefficient

x_i = x variable samples

y_i = y variable sample

\bar{x} = mean of values in x variable

\bar{y} = mean of values in y variable

เวลาที่	อุณหภูมิ °C (x_i)	#น้ำแข็งใส (y_i)
1	23	66
2	26	75
3	25	70
4	30	81
5	33	86
6	26	72
7	26	90
8	30	80
9	25	73
10	29	78
11	41	99
12	37	95
13	23	60
14	23	63
15	33	86

เวลาที่	อุณหภูมิ °C (xi)	#น้ำแข็งใส (yi)	xi_bar	yi_bar	xi - xi_bar (Xi)	yi - yi_bar (Yi)	Xi*Yi	$\sum Xi*Yi$	Xi^2	Yi^2	$\sum Xi^2$	$\sum Yi^2$	$\sqrt{\sum Xi^2 * \sum Yi^2}$	Correlation Coefficient (r)
1	23	66	28.67	78.27	-5.67	-12.27	69.51	771.33	32.11	150.47	407.33	1840.93	865.95	0.89
2	26	75	28.67	78.27	-2.67	-3.27	8.71	771.33	7.11	10.67	407.33	1840.93	865.95	0.89
3	25	70	28.67	78.27	-3.67	-8.27	30.31	771.33	13.44	68.34	407.33	1840.93	865.95	0.89
4	30	81	28.67	78.27	1.33	2.73	3.64	771.33	1.78	7.47	407.33	1840.93	865.95	0.89
5	33	86	28.67	78.27	4.33	7.73	33.51	771.33	18.78	59.80	407.33	1840.93	865.95	0.89
6	26	72	28.67	78.27	-2.67	-6.27	16.71	771.33	7.11	39.27	407.33	1840.93	865.95	0.89
7	26	90	28.67	78.27	-2.67	11.73	-31.29	771.33	7.11	137.67	407.33	1840.93	865.95	0.89
8	30	80	28.67	78.27	1.33	1.73	2.31	771.33	1.78	3.00	407.33	1840.93	865.95	0.89
9	25	73	28.67	78.27	-3.67	-5.27	19.31	771.33	13.44	27.74	407.33	1840.93	865.95	0.89
10	29	78	28.67	78.27	0.33	-0.27	-0.09	771.33	0.11	0.07	407.33	1840.93	865.95	0.89
11	41	99	28.67	78.27	12.33	20.73	255.71	771.33	152.11	429.87	407.33	1840.93	865.95	0.89
12	37	95	28.67	78.27	8.33	16.73	139.44	771.33	69.44	280.00	407.33	1840.93	865.95	0.89
13	23	60	28.67	78.27	-5.67	-18.27	103.51	771.33	32.11	333.67	407.33	1840.93	865.95	0.89
14	23	63	28.67	78.27	-5.67	-15.27	86.51	771.33	32.11	233.07	407.33	1840.93	865.95	0.89
15	33	86	28.67	78.27	4.33	7.73	33.51	771.33	18.78	59.80	407.33	1840.93	865.95	0.89

ค่า **Correlation Coefficient = 0.89**
อุณหภูมิมีความสัมพันธ์กับปริมาณการซื้อน้ำแข็งใส

CORRELATION สหสัมพันธ์

Netflix Example

Suppose we have 4 people who have rated movies on a scale of 1 to 5 stars with 1 being disliking the movie and 5 being loving the movie.

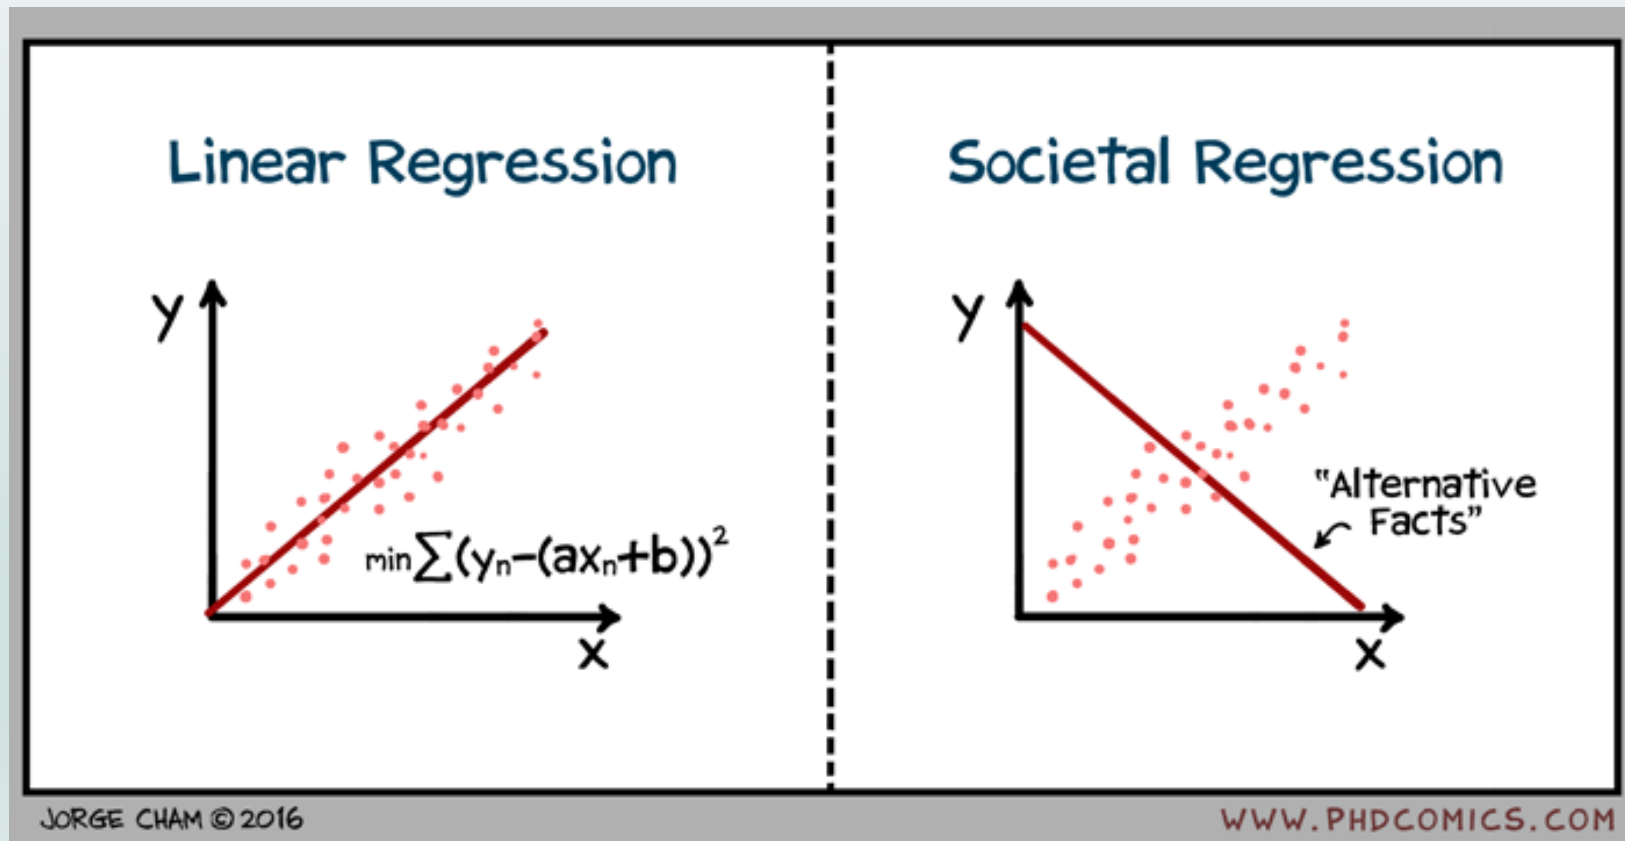
Movie	Adam	Lindsay	Austin	Sarah
Top Gun	4	1	5	2
Jurassic Park	5	2	5	3
Office Space	5	3	5	1
Message in a Bottle	1	4	1	5
Sleepless in Seattle	1	5	1	1
Titanic	4	1	5	3
Predator	5	2	5	2
Terminator	5	3	5	2
Anchorman	5	4	5	2

CORRELATION สหสัมพันธ์

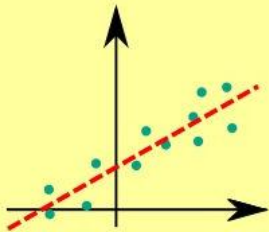
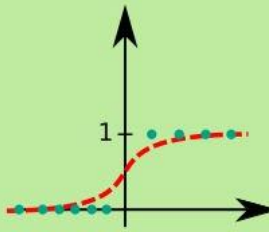
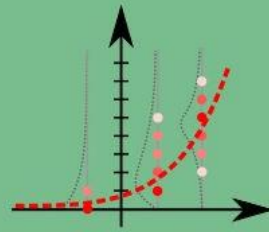
ค่า r

	Adam	Lindsay	Austin	Sarah
Adam	1	-0.54	0.97	-0.34
Lindsay	-0.54	1	-0.7	-0.1
Austin	0.97	-0.7	1	-0.31
Sarah	-0.34	-0.1	-0.31	1

REGRESSION สมการถดถอย



REGRESSION สมการถดถอย

LINEAR REGRESSION	LOGISTIC REGRESSION	POISSON REGRESSION
<ul style="list-style-type: none">1 Econometric modelling2 Marketing Mix Model3 Customer Lifetime Value	<ul style="list-style-type: none">1 Customer Choice Model2 Click-through Rate3 Conversion Rate4 Credit Scoring	<ul style="list-style-type: none">1 Number of orders in lifetime2 Number of visits per user
		
Continuous \Rightarrow Continuous	Continuous \Rightarrow True/False	Continuous \Rightarrow 0,1,2,...
$y = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$	$y = \frac{1}{1 + e^{-z}}$ $z = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$	$y \sim \text{Poisson}(\lambda)$ $\ln \lambda = \alpha_0 + \sum_{i=1}^N \alpha_i x_i$
<code>lm(y ~ x1 + x2, data)</code>	<code>glm(y ~ x1 + x2, data, family=binomial())</code>	<code>glm(y ~ x1 + x2, data, family=poisson())</code>
1 unit increase in x increases y by α	1 unit increase in x increases log odds by α	1 unit increase in x multiplies y by e^α

MarketingDistillery.com is a group of practitioners in the area of e-commerce marketing.

This Photo by Unknown Author is licensed under [CC BY-SA](#)

LINEAR REGRESSION การถดถอยเชิงเส้น

เป็นการอธิบายลักษณะความสัมพันธ์ระหว่างตัวแปร ว่าตัวแปรตัวหนึ่งหรือหลายตัว มีอิทธิพลต่อตัวแปรอีกตัวหนึ่งอย่างไร

X ตัวแปรต้น (Independent variable) : ควบคุมและวัดค่าได้

Y ตัวแปรตาม (Dependent variable) : เปลี่ยนแปลงไปตามการเปลี่ยนแปลงของตัวแปรต้น

ใช้ในการสร้างแบบจำลองเพื่อพยากรณ์ค่าต่างๆ

Simple linear regression :

$$Y = aX + b$$

a คือ ค่าความชันของเส้นตรง

b คือ ค่าที่ตัดกับเส้นแกน Y

LINEAR REGRESSION การถดถอยเชิงเส้น

การประมาณค่า **a** กับ **b** โดยใช้วิธีกำลังสองน้อยที่สุด (Least square estimation)


$$Y = aX + b$$

a คือ ค่าความชันของเส้นตรง

b คือ ค่าที่ตัดกับเส้นแกน Y

$$a = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

$$b = \bar{y} - a\bar{x}$$



ตัวอย่าง


การศึกษาราคาบ้าน (Housing Price)

บ้านหลังที่	ขนาดบ้าน (X)	ราคาบ้าน (Y)
1	1705	30859
2	1785	39759
3	1430	33232
4	1429	24158
5	2120	56310
6	2002	46101
7	1460	25727
8	1787	34780
9	2021	45137
10	2049	47411

ตัวอย่าง

บ้านหลังที่	ขนาดบ้าน (xi)	ราคาบ้าน (yi)	\bar{x}	\bar{y}	$X_i = x_i - \bar{x}$	$Y_i = y_i - \bar{y}$	$X_i * Y_i$	$\sum X_i * Y_i$	X_i^2	$\sum X_i^2$	\hat{a}
1	1705	30859	1778.8	38347.4	-73.8	-7488.4	552643.92	23256098.8	5446.44	649111.6	35.828
2	1785	39759	1778.8	38347.4	6.2	1411.6	8751.92	23256098.8	38.44	649111.6	
3	1430	33232	1778.8	38347.4	-348.8	-5115.4	1784251.52	23256098.8	121661.44	649111.6	
4	1429	24158	1778.8	38347.4	-349.8	-14189.4	4963452.12	23256098.8	122360.04	649111.6	
5	2120	56310	1778.8	38347.4	341.2	17962.6	6128839.12	23256098.8	116417.44	649111.6	
6	2002	46101	1778.8	38347.4	223.2	7753.6	1730603.52	23256098.8	49818.24	649111.6	
7	1460	25727	1778.8	38347.4	-318.8	-12620.4	4023383.52	23256098.8	101633.44	649111.6	
8	1787	34780	1778.8	38347.4	8.2	-3567.4	-29252.68	23256098.8	67.24	649111.6	
9	2021	45137	1778.8	38347.4	242.2	6789.6	1644441.12	23256098.8	58660.84	649111.6	
10	2049	47411	1778.8	38347.4	270.2	9063.6	2448984.72	23256098.8	73008.04	649111.6	

ตัวอย่าง



ตัวอย่าง

บ้านหลังที่	ขนาดบ้าน (X)	ราคาบ้าน (Y)	ราคาบ้านคาดการณ์ (Y_hat)	Error Term (e = Y-Y_hat)	e ²	LSE (Σe^2)
1	1705	30859	35703.74	-4844.74	23471505.67	135,387,027.64
2	1785	39759	38569.98	1189.02	1413768.56	
3	1430	33232	25851.04	7380.96	54478570.52	
4	1429	24158	25815.212	-1657.212	2746351.613	
5	2120	56310	50572.36	5737.64	32920512.77	
6	2002	46101	46344.656	-243.656	59368.24634	
7	1460	25727	26925.88	-1198.88	1437313.254	
8	1787	34780	38641.636	-3861.636	14912232.6	
9	2021	45137	47025.388	-1888.388	3566009.239	
10	2049	47411	48028.572	-617.572	381395.1752	

MULTIPLE REGRESSION


ในความเป็นจริงแล้วเราไม่ได้ตัดสินใจว่าราคาบ้านควรจะเป็นเท่าไร

“จากปัจจัยขนาดของบ้านเท่านั้น”

แต่เราอาจจะมีปัจจัยอื่นๆมาใช้ในการตัดสินใจด้วย เช่น จำนวนห้อง, ปริมาณที่จอดรถ, เพอร์นิเจอร์ภายในบ้าน

ตัวแปรต้น (X) ที่ใช้จะมีมากกว่า 1 ตัว

$$Y = \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$



OPTIMIZATION LINEAR PROGRAMMING

เป็นวิธีการหาค่าที่ดีที่สุด ภายใต้เงื่อนไข/ข้อจำกัด/ทรัพยากร

$$\begin{aligned} &\text{maximize} && c_1x_1 + c_2x_2 + \cdots + c_nx_n \\ &\text{subject to} && a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n \leq b_1 \\ & && a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n \leq b_2 \\ & && \vdots \\ & && a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n \leq b_m \\ & && x_1, x_2, \dots, x_n \geq 0. \end{aligned}$$

We shall refer to linear programs formulated this way as linear programs in *standard form*. We shall always use m to denote the number of constraints, and n to denote the number of decision variables.

[This Photo](#) by Unknown Author is licensed under [CC BY-SA](#)

OPTIMIZATION LINEAR PROGRAMMING

การประยุกต์ใช้ \Rightarrow กำไรสูงสุด / ต้นทุนต่ำสุด

- อุตสาหกรรมปิโตรเลียม : สูตรผสมน้ำมันดิบ
- ภาคการผลิต : **inventory, overtime**
- อุตสาหกรรมอาหาร : **shipping plan**
- การแพทย์ : **nutrition**
- การสื่อสาร : **network**

Maximization problem

Objective function $c^T x = c_1 x_1 + c_2 x_2 + \dots + c_n x_n$

ที่สอดคล้องกับ constraints

$$\left. \begin{array}{l} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n \leq b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n \leq b_2 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n \leq b_n \end{array} \right\} (Ax \leq b)$$
$$x_i \geq 0, \quad i = 1, 2, \dots, n$$

จะได้แบบฟอร์มทั่วไปของปัญหาในการหาค่าสูงสุด คือ

Maximize $c^T x$

Subject to: $Ax \leq b$

$$x \geq 0$$

Minimization problem

Objective function $y^T b = y_1 b_1 + y_2 b_2 + \dots + y_m b_m$

ที่สอดคล้องกับ constraints

$$\left. \begin{array}{l} y_1 a_{11} + y_2 a_{21} + \dots + y_m a_{m1} \geq c_1 \\ y_1 a_{12} + y_2 a_{22} + \dots + y_m a_{m2} \geq c_2 \\ \vdots \\ y_1 a_{1n} + y_2 a_{2n} + \dots + y_m a_{mn} \geq c_n \end{array} \right\} (y^T A \geq c^T)$$
$$y_i \geq 0, \quad i = 1, 2, \dots, n$$

จะได้แบบฟอร์มทั่วไปของปัญหาในการหาค่าต่ำสุด คือ

Minimize $y^T b$

Subject to: $y^T A \geq c^T$

$$y \geq 0$$

GRAPHICAL METHOD

Maximize $z = 5x_1 + 4x_2$

ที่สอดคล้องกับ constraints:

$$6x_1 + 4x_2 \leq 24 \quad (1)$$


$$x_1 + 2x_2 \leq 6 \quad (2)$$

$$-x_1 + x_2 \leq 1 \quad (3)$$

$$x_2 \leq 2 \quad (4)$$

$$x_1 \geq 0 \quad (5)$$

$$x_2 \geq 0 \quad (6)$$



PIVOT METHOD

	s_1	\cdots	s_j	\cdots	s_n
y_1	a_{11}	\cdots	a_{1j}	\cdots	a_{1n}
\vdots	\vdots		\vdots		\vdots
y_i	a_{i1}	\cdots	a_{ij}	\cdots	a_{in}
\vdots	\vdots		\vdots		\vdots
y_m	a_{m1}	\cdots	a_{mj}	\cdots	a_{mn}



	s_1	\cdots	y_i	\cdots	s_n
y_1	\hat{a}_{11}	\cdots	\hat{a}_{1j}	\cdots	\hat{a}_{1n}
\vdots	\vdots		\vdots		\vdots
s_j	\hat{a}_{i1}	\cdots	\hat{a}_{ij}	\cdots	\hat{a}_{in}
\vdots	\vdots		\vdots		\vdots
y_m	\hat{a}_{m1}	\cdots	\hat{a}_{mj}	\cdots	\hat{a}_{mn}

SIMPLEX METHOD

$$-y^T A + s^T = -c^T$$

y_1	y_2	...	y_n	s_1	s_2	...	s_m	Solution constant
$-a_{11}$	$-a_{12}$...	$-a_{1n}$	1	0	...	0	$-c_1$
$-a_{21}$	$-a_{22}$...	$-a_{2n}$	0	1	...	0	$-c_2$
\vdots	\vdots	\ddots	\vdots	\vdots	\vdots	\ddots	\vdots	\vdots
$-a_{m1}$	$-a_{m2}$...	$-a_{mn}$	0	0	...	1	$-c_m$
$-b_1$	$-b_2$...	$-b_n$	0	0	...	0	0

Simplex Tableau for minimization problem

WRAP UP

- การทดสอบสมมติฐาน
- การวิเคราะห์ความสัมพันธ์
- Scatter plot
- Correlation
- Regression
- Optimization Linear Programming

Q

&

A